

UFPB – Universidade Federal da Paraíba
Centro de Informática

Implementação e Benchmarking do Algoritmo Apriori Utilizando OpenMP

Nivaldo Mariano de Carvalho Júnior

2019

Roteiro

- Introdução
- Objetivos
- Metodologia
- Resultados Parciais
- Referências

Introdução

- Programação Paralela
 - Forma de computação que vários cálculos são realizados ao mesmo tempo (GOTTlieb, 1989).
 - Tem como princípio que grandes problemas podem ser divididos em problemas menores, para serem resolvidos concorrentemente (GOTTlieb, 1989)
- OpenMP (Open Multi-Processing)
 - É uma API multi-plataforma (open-source) para processamento paralelo baseado em memória compartilhada (SILVA, 2007)
 - Possui implementações em compiladores das linguagens C, C++ e Fortran (SILVA, 2007)
 - Consiste em um conjunto de diretivas, bibliotecas e variáveis de ambiente para o compilador

Exemplo: `#pragma omp parallel`

Introdução

- Algoritmo Apriori

- É um dos algoritmos mais famosos para Mineração de Dados, proposto por Agrawal et al em 1993 para busca de padrões em bancos de dados (BARANAUSKAS, 2007)
- Os conjuntos de itens frequentes determinados pelo Apriori podem ser usados para determinar Regras de Associação (JABEEN, 2018)
- Também utilizado na análise de cesta de compras em supermercados para determinar como itens comprados por clientes estão relacionados (BARANAUSKAS, 2007)
- O Algoritmo Apriori é um algoritmo custoso, pois usa uma abordagem de força bruta (BOGORNÝ, 2000)
- A complexidade do mesmo pode chegar a $O(NMw)$, sendo **N** a quantidade de transações, **M** o número de itens candidatos de uma associação e **w** a quantidade de itens de uma transação (BOGORNÝ, 2000)

Introdução

■ Algoritmo Apriori

- No algoritmo, dado um conjunto de transações (input), ele encontra regras para a predição de ocorrência de itens baseado na ocorrência de outros itens na mesma transação (BOGORNÝ, 2000)

Exemplo^[7]:

ID da Transação	Produtos Comprados
1	Pão, Leite
2	Pão, Fraldas, Cerveja, Ovos
3	Leite, Fraldas, Cerveja, Coca
4	Pão, Leite, Fraldas, Cerveja
5	Pão, Leite, Fraldas, Coca

Exemplo de Regra de Associação^[7]:

{fraldas} -> {**cerveja**} (~75%),
{leite, pão} -> {**ovos, coca**} (~60%),
{cerveja, pão} -> {**leite**} (~33%)

Objetivos

- Implementação do Apriori na linguagem C++
 - Código serial (single-thread)
 - Código paralelo (multi-thread)
- Teste de ambas abordagens utilizando uma amostra de dados reais
 - Dados obtidos no Kaggle
 - Base de dados de compras/transações de um supermercado
- Benchmark das duas implementações

Metodologia

- Implementar o Algoritmo Apriori na linguagem C++
 - Adaptação do Apriori para frequência de até dois itens, originalmente desenvolvido como uma procedure MySQL
 - Será realizado testes com dados de diferentes tamanhos de entrada (N)
 - Para cada tamanho de entrada, será feita a medição do tempo de execução para o algoritmo serial e paralelo
 - Serial: Biblioteca `<time.h>` e `clock()`
 - Paralelo: Função `omp_get_wtime()` da `<omp.h>`


Metodologia

- Ambiente de benchmark e desenvolvimento
 - Intel Core i7-7500U
 - Frequência de 2.70GHz (máx. 3.5GHz)
 - Cache L1 128KB, Cache L2 512KB, Cache L3 4MB
 - 2-cores, 4 threads
 - 8GB RAM DDR4-2133MHz
 - Compilador g++ (MinGW.org GCC-8.2.0-3) 8.2.0
 - Windows 10 Pro 17763.475 (64-bit)

Metodologia

- Conjunto de dados oriundo do Kaggle Datasets
- Será realizado o processo de limpeza dos dados
 - Python e as bibliotecas Pandas & Numpy
 - Dados separados em três conjuntos de dados
 - 1) Com 21 linhas, 10 transações distintas e 7 produtos distintos
 - 2) Com 100 linhas, 20 transações distintas e 10 produtos distintos
 - 3) Com 500 linhas, 30 transações distintas e 20 produtos distintos
 - 4) Com 1000 linhas, 40 transações distintas e 30 produtos distintos


Resultados Parciais



Resultados Parciais

	<i>Tempo em Segundos (serial vs 4 threads)</i>							
	<i>n = 21</i>		<i>n = 100</i>		<i>n = 500</i>		<i>n = 1000</i>	
#	Serial	OpenMP	Serial	OpenMP	Serial	OpenMP	Serial	OpenMP
1	0.005	0.00600004	0.012	0.013	0.957	0.847	3.392	2.32
2	0.006	0.00600004	0.017	0.013	0.97	0.839	3.038	2.351
3	0.003	0.00699997	0.014	0.013	0.919	0.819	3.096	2.304
4	0.003	0.00600004	0.015	0.0140002	0.8	0.745	3.035	2.282
5	0.006	0.00600004	0.013	0.013	0.944	0.827	3.056	2.369
6	0.005	0.00600004	0.014	0.013	0.942	0.846	3.072	2.291
7	0.006	0.00600004	0.014	0.0139999	0.903	0.8	3.025	2.274
8	0.004	0.00699997	0.012	0.013	0.925	0.753	3.07	2.326
9	0.004	0.00600004	0.012	0.0139999	0.909	0.78	3.088	2.365
10	0.006	0.00699997	0.012	0.0139999	0.89	0.684	3.045	2.306


Resultados Parciais



Resultados Parciais

	<i>Tempo em Segundos (1, 2 & 4 threads)</i>					
	variável de ambiente (path) OMP_NUM_THREADS					
	<i>n = 500</i>			<i>n = 1000</i>		
	1 thread	2 threads	4 threads	1 thread	2 threads	4 threads
1	0.931	0.786	0.644	3.04	2.387	2.324
2	0.895	0.892	0.671	2.672	2.259	2.049
3	0.808	0.868	0.7	2.653	2.166	1.996
4	0.955	0.782	0.708	2.686	2.136	1.999
5	0.923	0.801	0.643	2.599	2.201	2.366
6	0.79	0.656	0.698	2.664	2.101	2.061
7	0.841	0.73	0.691	2.713	2.121	2.014
8	0.871	0.691	0.687	2.699	2.215	1.984
9	0.838	0.693	0.618	2.657	2.145	2.01
10	0.919	0.721	0.668	2.669	2.135	1.985

Resultados Parciais



Referências

- [1] Almasi, G.S. e A. Gottlieb (1989). *Highly Parallel Computing*. Benjamin-Cummings, Redwood City, CA.
- [2] SILVA, Fernando (2007). DCC-FCUP. Introdução ao OpenMP. Disponível em: <https://www.dcc.fc.up.pt/~fds/aulas/PPD/0708/intro_openmp-1x2.pdf>
- [3] Rakesh Agrawal and Ramakrishnan Srikant Fast algorithms for mining association rules in large databases. Proceedings of the 20th International Conference on Very Large Data Bases, VLDB, pages 487-499, Santiago, Chile, September 1994.
- [4] SILVA, Michel de A. Aplicação do Algoritmo Apriori para uma base de dados de ictioplâncton em um reservatório de água doce da Amazônia Legal. Disponível em: <<http://www.lbd.dcc.ufmg.br/colecoes/eniac/2013/0038.pdf>>
- [5] BARANAUSKAS, José Augusto (2007). Departamento de Física e Matemática - FFCLRP-USP. Regras de Associação. Disponível em: <<http://dcm.ffclrp.usp.br/~augusto/teaching/ami/AM-I-Regras-Associacao.pdf>>
- [6] JABEEN, Hafsa. DataCamp, 2018. Market Basket Analysis using R. Disponível em: <<https://www.datacamp.com/community/tutorials/market-basket-analysis-r>>
- [7] BOGORNY, Vania, 2000. Apresentação adaptada do material do livro: Introduction to Data Mining - Tan, Steinbach e Kumar. Disponível em: <www.inf.ufsc.br/~vaniã/teaching/INE5644/RegrasDeAssociacao.ppt>
- [8] KAGGLE, 2019. SalesDB Grocery Market. Disponível em: <<https://www.kaggle.com/marcinex1423/salesdb-grocery>>
- [9] MELO, Humberto Gustavo de. Devmedia, 2008. Algoritmo Apriori no MySQL Utilizando Procedure. Disponível em: <<https://www.devmedia.com.br/algoritmo-apriori-no-mysql-utilizando-procedure/9930>>